



2026

Технологии теории игр

Causal MARL-модель для прогнозирования криптоиндикаторов платформы Santiment

Выполнила:

Ракич Тина

студентка 1-го курса магистратуры

МиКМ 25

СОДЕРЖАНИЕ

-
- 01** Введение
 - 02** Цель и постановка задачи
 - 03** Методология
 - 04** Данные
 - 05** Эмпирические результаты
 - 06** Выводы
 - 07** Дальнейшее развитие

01 ВВЕДЕНИЕ

Мультиагентная природа криптовалютного рынка

Рыночная динамика формируется в результате взаимодействия трейдеров, маркет-мейкеров, бирж и других агентов, что позволяет рассматривать крипторынок как мультиагентную систему и применять методы теории игр для ее анализа.

Каузальный анализ как основа интерпретируемого прогнозирования

Традиционные модели прогнозирования временных рядов часто не различают корреляционные и причинно-следственные зависимости, что снижает их устойчивость и интерпретируемость.

Для криптобирж и аналитических платформ важно не просто прогнозировать изменения показателей, а понимать механизмы их возникновения.

Интеграция методов причинно-следственного анализа с прогностическими моделями с помощью инструментария теории игр позволит выявлять ключевые драйверы рынка, объяснять взаимосвязи между индикаторами и создавать более прозрачные инструменты поддержки принятия решений.

Такой подход может стать основой продуктовых решений нового поколения: от интерпретируемых прогнозных моделей до систем мониторинга рыночных рисков и поведения участников рынка.

02 ЦЕЛЬ ПРОЕКТА

Разработка аналитического модуля для платформы Santiment на основе каузального многоагентного обучения с подкреплением (Causal MARL), способного прогнозировать криптоиндикаторы и раскрывать скрытые причинно-следственные связи, обеспечивая интерпретируемую аналитику и моделирование стратегического взаимодействия участников крипторынка.

•santiment•

ПЛАТФОРМА
ДАННЫХ

CAUSAL
DISCOVERY

MARL

FORECAST

•santiment•

СТРАТЕГИЧЕСКИЙ
ИСТОЧНИК ИНСАЙТОВ
КРИПТОРЫНКА

02 ЗАДАЧИ ПРОЕКТА

01

Формализация Causal MARL подхода

- Концептуализация подхода к Causal MARL в виде математической модели

02

Подготовка и предобработка данных

- Предобработка криптоиндикаторов Santiment для анализа
- Построение причинно-следственной модели методами causal discovery

03

Разработка и обучение Causal MARL


- Создание многоагентной RL-системы обучения для прогнозирования показателей
- Обучение разработанной модели

04

Продуктовая интеграция

- Создание интерфейса для аналитической платформы для поддержки принятия решений

03 МЕТОДОЛОГИЯ



ОБЩАЯ СХЕМА ЗАДАЧИ CRL

CAUSAL DISCOVERY

На первом этапе должна быть выявлена структурная причинно-следственная модель (Structural Causal Model) для заданных временных рядов. В результате работы методов causal discovery будет построен каузальный граф (causal graph), который является источником информации об окружении для агентов.

MULTI-AGENT CRL FORECASTING

На втором этапе задача CRL рассматривается как кооперативная мультиагентная система, в которой каждый агент прогнозирует отдельный временной ряд, учитывая причинно-следственные взаимодействия с другими агентами и совместно максимизируя общую функцию награды.

03 ЭТАП I - SCM

Структурная причинно-следственная модель (Structural Causal Model, SCM) – это $\mathcal{M}^* = \langle U, V, \mathcal{F}, P \rangle$

где: $U = \{U_1, U_2, \dots, U_K\}$ - множество экзогенных переменных,

$V = \{V_1, V_2, \dots, V_n\}$ - множество эндогенных переменных,


$\mathcal{F} = \{f_i: V_i \in V\}$ – множество структурных функций, определяющих зависимость V_i от «родителей» и экзогенных факторов $v_i \leftarrow f_i(pa_i, u_i)$,

$P(U)$ - вероятностное распределение экзогенных переменных.

Агент действует в соответствии с причинно-следственной моделью принятия решений (Causal Decision Model, CDM) $\langle \mathcal{M}^*, \Pi, \mathcal{R} \rangle$, где $\mathcal{M}^*$ – заданная SCM, Π – пространство стратегий, или последовательностей действий над $X \subseteq V$, а $\mathcal{R}$ – функция наград по отношению к сигналам $Y \subseteq V$.

Оптимальной стратегией агента π^* для $\langle \mathcal{M}^*, \Pi, \mathcal{R} \rangle$ является стратегия из пространства Π , максимизирующая функцию наград $\mathcal{R}$ вычисляемую на основе SCM $\mathcal{M}^*$, т.е. $\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi}[\mathcal{R}(Y), \mathcal{M}^*]$

Причинно-следственная
диаграмма $\mathcal{G}$



03 ЭТАП I – АЛГОРИТМ РСМСИ

PCMSI (Peter and Clark Momentary Conditional Independence)

Рассмотрим систему временных рядов $X_t = (X_t^1, \dots, X_t^N)$

$$X_t^j = f_j(P(X_t^j), \eta_t^j)$$

где:
 f_j обозначает нелинейную функциональную зависимость, η_t^j – независимый шум в данных,
а $P(X_t^j) \subset X_t^- = (X_{t-1}, X_{t-2}, \dots)$ – это множество «родителей» переменной X_t^j

Причинно-следственная связь $X_{t-\tau}^i \rightarrow X_t^j$ существует, если $X_{t-\tau}^i \in P(X_t^j)$.

01

PC₁ – отбор признаков для выделения релевантных наборов «родителей» $\hat{P}(X_t^j)$ для всех временных рядов $X_t^j \in \{X_t^1, \dots, X_t^N\}$

02

Тестирование на мгновенную условную независимость (Momentary Conditional Independence, MCI) для проверки существования причинной связи $X_{t-\tau}^i \rightarrow X_t^j$
 $MCI: X_{t-\tau}^i \perp\!\!\!\perp X_t^j \mid \hat{P}(X_t^j) \setminus \{X_{t-\tau}^i\}, \hat{P}(X_{t-\tau}^i)$
Если гипотеза не отклоняется, ребро графа, связывающее $X_{t-\tau}^i$ и X_t^j удаляется.

03 ЭТАП II – CAUSAL MARL

Пусть имеется SCM $\mathcal{M}^* = \langle U, V, \mathcal{F}, P \rangle$ и известна ее причинно-следственная диаграмма $\mathcal{G}$.
 $\mathcal{N} = \{1, 2, 3, \dots, N\}$ - множество агентов, каждый из которых выполняет прогноз признака $V_n \in V$.

Наблюдения агента: $o_t^n = z_{t-L+1:t}^n = \{z_\tau^n \in \mathbb{R}^{F_n} \mid \tau = \{t-L+1, \dots, t\}\} \in o^n$
 F_n – представляет набор входных признаков для агента n и состоит из $PA_i \subseteq V \setminus \{V_i\}$ и $U_i \subseteq U$

Глобальное наблюдение для всех агентов: $o_t = \{o_t^n \in \mathbb{R}^{F_n \times L} \mid n = \{1, 2, \dots, N\}\} \in \mathcal{O}$

Действия агентов – прогноз на H шагов вперед:

$$a_t^n = \hat{z}_{t+1:t+H}^n = \{\hat{z}_\tau^n \in \mathbb{R}^{F_n} \mid \tau = \{t+1, \dots, t+H\}\}$$

В каждый момент времени все агенты совершают действия одновременно на основе своих наблюдений.
На каждом шаге все агенты получают совместное вознаграждение $\mathcal{R}(o_t, a_t): \mathcal{O} \times \mathcal{A} \rightarrow \mathbb{R}$

Награда – отрицательная средняя абсолютная ошибка MAE:

$$r_t = MAE(\hat{z}_{t+1:t+H}) = \frac{1}{H \cdot N} \sum_{h=1}^H \sum_{n=1}^N |z_{t+h}^n - \hat{z}_{t+h}^n|$$

ОЗ ЭТАП II – АРХИТЕКТУРА

АГЕНТ

Полученное в момент времени t нблюдение o_t^n подается на вход LSTM энкодера. Последнее скрытое состояние h_t используется в actor-critic архитектурой. Actor формирует параметры гауссовского распределения действий

$$\pi(a_t^n | o_t^n) = \mathcal{N}(\mu_t^n, \sigma_t^n),$$

где μ_t^n - среднее значение действий, формируемое из скрытого слоя, σ_t^n - стандартное отклонение, задающее масштаб расброса действий. Critic вычисляет оценку состояния агента.

ОБУЧЕНИЕ

Обучение проводится по PPO (Proximal Policy Optimization) actor-critic схеме с функцией потерь

$$\mathcal{L} = \mathcal{L}_{actor} + 0,5\mathcal{L}_{critic} - 0,001\mathcal{L}_{entropy}$$

где $\mathcal{L}_{actor} = -\mathbb{E}[\log(\pi(a_t^n | o_t^n))A_t^n]$, $\mathcal{L}_{critic} = -\mathbb{E}[(V(o_t^n) - R_t)^2]$, а преимущества A_t^n вычисляются через GAE (Generalized Advantage Estimation)

$$A_t^n = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}^n, \delta_t^n = r_t^n + \gamma(V(o_{t+1}^n) - V(o_t^n)).$$

Награда агента определяется как отрицательная средняя абсолютная ошибка -MAE.

СРЕДА

Среда предоставляет информацию о причинно-следственных связях на основе SCM. Состояние агента формируется из скользящего окна собственных исторических значений и историй причинных родителей.

ОЗ ОБОСНОВАНИЕ ПОДХОДА

Взаимозависимость

Криптоиндикаторы связаны причинно-следственными зависимостями. SCM отфильтровывает шум и выделяет ключевые связи.

Кооперация

Рынок является мультиагентной системой с взаимным влиянием участников. Совместное обучение позволяет учитывать системные эффекты.

Непрерывность

Криптопоказатели являются непрерывными и волатильными. Гауссовское распределение моделирует прогноз и неопределенность.

Временные зависимости

Рынок имеет выраженные лаги и долгосрочные эффекты. LSTM извлекает временные зависимости из истории.

Интерпретируемость

Важно объяснять причины прогнозов. Каузальный граф показывает влияние индикаторов.

Устойчивость

Ряды нестационарны и шумны. Обучение с RL и относительные ошибки повышают стабильность.

Масштабируемость

Модель расширяется добавлением новых агентов. Архитектура сохраняет структуру без переработки.


Сценарный анализ

SCM позволяет проводить причинный анализ. Модель оценивает последствия гипотетических изменений.

04 ДАННЫЕ

В исходном наборе представлены почасовые значения 441 показателя, данные по котором предоставляет платформа Santiment, за период с 1 января 2018 г., 00:00 по 29 июня 2025 г., 20:00.

Для данного проекта рассмотрена выборка с 1 января 2025 г., 00:00 по по 29 июня 2025 г., 20:00.



BITCOIN

- Самая известная и ликвидная криптовалюта
- Представляет базовый рынок криптовалют («цифровое золото»)

ETHEREUM

- Основная платформа для смарт-контрактов, DeFi и NFT
- Позволяет изучать активность сети

THETER

- Стейблкоин, привязанный к доллару США
- Отличается минимальной волатильностью, что позволяет анализировать ликвидность и объемы торгов

CHAINLINK

- Инфраструктурный токен, связывающий блокчейны с внешними данными
- Интересен для анализа связей с смарт-контрактами

SANTIMENT

- Позволяет глубже понять структуру рынка
- Источник информации о поведенческих характеристиках участников рынка

04 ПРЕДОБРАБОТКА

ШАГ 1. УДАЛЕНИЕ НУЛЕВЫХ ЗНАЧЕНИЙ

Отброшены все признаки, содержащие меньше 95% не-нулевых значений

ШАГ 3. УДАЛЕНИЕ ВЗАИМНО ДЕТЕРМИНИРОВАННЫХ ПРИЗНАКОВ

Удалены признаки с высокой степенью корреляции ($\rho > 0,99$)


ШАГ 2. LOW-VARIANCE & SPARSITY FILTERING

Удалены признаки близки к константе, с небольшой дисперсией и редкими пиками в значениях


ШАГ 4. "ЭКСПЕРТНЫЙ ОТБОР"

Отброшены признаки совпадающие по смыслу, или предоставляющие дублирующую информацию

39
ПРИЗНАКОВ




4318
НАБЛЮДЕНИЙ



05 ЭМПИРИЧЕСКИЕ РЕЗУЛЬТАТЫ

Построенный граф, позволяет увидеть:

- устойчивый базовый механизм: активность адресов → рост транзакций → изменение биржевых потоков
- сильную связь BTC – ETH – LINK через network growth, supply on exchanges и whale activity
- tether выступает системным узлом, влияя не только на себя, но и на другие активы через депозитные потоки
- whale-активность функционирует как координирующий механизм между рынками
- sentiment-метрики демонстрируют глобальную мультиактивную связанность, а не локальный эффект отдельных активов
- метрики доли предложения на биржах (supply on exchanges) почти полностью синхронизированы между активами (0.97 – 0.99), что указывает на общий латентный рыночный фактор



05 ОБУЧЕНИЕ МОДЕЛИ

ТАБЛИЦА ЭКСПЕРИМЕНТОВ

НОМЕР	ЭПОХ	LOOKBACK	GAMMA	SCALER
1	100	48	0.98	z-метки
2	100	48	0.98	robust
3	300	48	0.98	z-метки
4	300	48	0.98	robust

В первых экспериментах применялись z-метки, однако из-за значительного разброса значений криптоиндикаторов модель обучалась менее эффективно. Поэтому далее был использован RobustScaler, устойчивый к выбросам, не искажающий получаемую награду.

SENSITIVITY ANALYSIS







Анализ чувствительности изменения совокупной награды к изменению параметра γ . Для представленного эксперимента оптимальным значением коэффициента дисконтирования γ является 0.98, так как оно обеспечивает наилучший итоговый reward и более устойчивое обучение в перспективе.

05 СРАВНЕНИЕ ЭКСПЕРИМЕНТОВ

STANDARD

100 ЭПОХ




ROBUST






05 СРАВНЕНИЕ ЭКСПЕРИМЕНТОВ

300 ЭПОХ

STANDARD



ROBUST



REWARD PER AGENT

ОБ ВЫВОДЫ

> 10 ЧАСОВ ОБУЧЕНИЯ

Агенты научилась строить сглаженные прогнозы с учетом причинно следственных-связей, но для создания production-ready решения необходимо добиться хорошей сходимости обучения, в т. ч. за счет увеличения выборки и решения проблемы разброса значений. Это потребует оптимизации вычислительной архитектуры.

Применение GAE позволяет эффективно снижать дисперсию оценки преимущества и улучшает устойчивость обучения actor-critic модели.

Разработанный подход на основе PPO + причинно-игрового AI-фреймворка позволяет не только прогнозировать поведение рынка, но и интерпретировать вклад отдельных агентов.


Наилучшие результаты обучения PPO достигаются при высоком коэффициенте дисконтирования $\gamma = 0,98$, что указывает на важность учета долгосрочных зависимостей в динамике крипторынка.

Агенты научились не только находить скрытые закономерности, но и действовать на основе причинно-следственных связей.

ОБ ФИНАЛЬНЫЙ РЕЗУЛЬТАТ

Функциональный аналитический модуль, который позволяет исследовать каузальную структуру между криптоиндикаторами и строить на их основе прогнозы с полным пониманием ключевых драйверов рынка.

Game-Theoretic AI
Framework for Crypto
Market Intelligence



ОБ ДАЛЬНЕЙШЕЕ РАЗВИТИЕ

01

ВЫЧИСЛИТЕЛЬНАЯ ОПТИМИЗАЦИЯ АЛГОРИТМА

Ускорение процесса обучения.
Оптимизация использования оперативной памяти.

02

УЛУЧШЕНИЕ СОХОДИМОСТИ ОБУЧЕНИЯ

Эксперименты с методами нормализации данных и различными функциями наград, а также с вариациями распределения действий агентов.

03

ПЕРЕХОД ОТ CAUSALTY-BASED ПОДХОДА К НАСТОЯЩЕМУ COUNTERFACTUAL REASONING

Научить агентов не только понимать происходящее, но и активно «действовать» на основе поступающих сигналов и «чувствовать» последствия своих действий. Переход к online RL с элементами *do*-calculus.


ЛИТЕРАТУРА

1. Bareinboim E., Zhang J., Lee S. An introduction to causal reinforcement learning // Columbia CausalAI Laboratory, Portland, OR, USA, Tech. Rep. 2024.
2. Bi Y. et al. Long-Term Financial Forecasting and Trading via Multi-Agent Reinforcement Learning // Proceedings of the 6th ACM International Conference on AI in Finance. 2025. P. 788-796. DOI:10.1145/3768292.3770411.
3. Börjesson L., Singull M. Forecasting financial time series through causal and dilated convolutional neural networks // Entropy. 2020. Vol. 22, no. 10. P. 1094. DOI: 10.3390/e22101094.
4. Grimbly S. J., Shock J., Pretorius A. Causal multi-agent reinforcement learning: Review and open problems // arXiv preprint arXiv:2111.06721. 2021. DOI: arXiv.2111.06721.
5. Htun H. H., Biehl M., Petkov N. Forecasting relative returns for S&P 500 stocks using machine learning // Financial Innovation. 2024. Vol. 10, no. 1. P. 118-133. DOI: 10.1186/s40854-024-00644-0.
6. Moraffah R. et al. Causal inference for time series analysis: Problems, methods and evaluation // Knowledge and Information Systems. 2021. Vol. 63, no. 12. P. 3041-3085. DOI: 10.1007/s10115-021-01621-0.
7. Runge J. et. al. Detecting and quantifying causal associations in large nonlinear time series datasets // Sci. Adv. 2019. Vol. 5. Article eaau4996. DOI: 10.1126/sciadv.aau4996
8. Runge J., Gerhardus A., Varando G. et al. Causal inference for time series // Nat. Rev. Earth Environ. 2023. Vol. 4. P. 487–505. DOI: 10.1038/s43017-023-00431-y
9. Tang Y. et al. A survey on machine learning models for financial time series forecasting // Neurocomputing. 2022. Vol. 512, P. 363-380. DOI: 10.1016/j.neucom.2022.09.003
10. Yu K. et al. Causality-based feature selection: Methods and evaluations // ACM Computing Surveys (CSUR). 2020. Vol. 53, no. 5. P. 1-36. DOI: 10.1145/3409382.
11. Zeng Y. et al. A survey on causal reinforcement learning // IEEE Transactions on Neural Networks and Learning Systems. 2024. Vol. 36, no. 4. P. 5942-5962. DOI: 10.1109/TNNLS.2024.3403001.



GitHub

Репозиторий проекта
tinarakic/ITMO_26_GameSMod



Благодарю за внимание!

**Causal MARL-модель для прогнозирования
Криптоиндикаторов платформы Santiment**